

Actividad — Semana 2: Clasificación de datos y las V del Big Data

Estudiante: Kevin Andres Cuevas Fuentes

Programa: Ingeniería Industrial

Asignatura: Ciencia de Datos

Institución: Corporación Universitaria del Huila — CORHUILA

Periodo: 2026-B

1. Fuentes de datos y clasificación por estructura

Se listan 6 fuentes del proyecto de optimización de inventario, clasificadas según su estructura:

Tabla

N°	Fuente de datos	Contenido principal	Tipo de dato
1	Sistema de inventarios / ERP	Código de producto, cantidades, fechas de entrada y salida, ubicación en bodega	Estructurado
2	Sistema de facturación y ventas	Producto vendido, fecha de transacción, cantidad vendida, valor unitario	Estructurado
3	Catálogo maestro de artículos	Código, categoría, línea de producto, tiempo de vida útil, proveedor	Estructurado
4	Registros de recepción de mercancía	Albaranes, remisiones, observaciones y anotaciones	Semiestructurado
5	Imágenes y fotografías de bodega	Fotografías de estantes, condiciones de almacenamiento, estado de productos	No estructurado
6	Comunicaciones con proveedores	Correos electrónicos, mensajes y acuerdos sobre entregas y plazos	No estructurado

Justificación de la clasificación

- Datos estructurados: Se organizan en tablas con campos definidos (filas y columnas), compatibles con bases de datos relacionales. Son fáciles de consultar y procesar.
- Datos semiestructurados: Tienen cierta organización pero no se ajustan a un esquema rígido; pueden contener campos variables o anotaciones libres.

- Datos no estructurados: No tienen formato ni organización predefinida; requieren técnicas especiales de procesamiento para extraer información útil.

Según el Departamento Nacional de Planeación (2020), esta distinción es fundamental porque determina las herramientas, los costos y las técnicas que se deben utilizar en cada caso.

2. Las 5 V del Big Data — Identificación de las relevantes

Tabla

V	Nivel de relevancia	¿Por qué es importante?
Volumen	Alta	Se acumulan registros de meses o años. Cuantos más registros históricos se tengan, mayor precisión al identificar patrones de rotación por temporada.
Velocidad	Media-Alta	Los registros de inventario y ventas se actualizan continuamente. Si la información llega tarde o se procesa con retraso, las decisiones se toman sobre datos desactualizados.
Variedad	Media	Se combinan datos de distinto tipo. La capacidad de integrarlos es necesaria para obtener una visión completa del inventario.
Veracidad	Muy alta	Datos erróneos, duplicados o inconsistentes pueden hacer que el análisis indique conclusiones falsas. Sin fiabilidad en los datos, el análisis no sirve.
Valor	Muy alta	Es la finalidad de todo el proyecto: transformar los datos en decisiones que generen ahorro, reduzcan pérdidas y optimicen recursos. Si no se genera valor medible, el proyecto carece de justificación.

Conclusión sobre las V críticas

Las tres dimensiones más determinantes en este proyecto son: Veracidad, Valor y Volumen. Sin veracidad los datos no se pueden confiar; sin volumen suficiente no se distinguen patrones de comportamiento; y sin valor el análisis no tiene propósito empresarial.

Referencia: Laney, D. (2017). Marco de las 5 V del Big Data, adoptado como referencia por el Departamento Nacional de Planeación y entidades públicas en Colombia.

3. Reto de veracidad — Problema de calidad y forma de detectarlo

Problema identificado

Inconsistencias y errores en los registros: movimientos duplicados, fechas en que la entrada es posterior a la salida, o cantidades que no coinciden con el inventario físico. Estos errores distorsionan los cálculos de rotación y pueden hacer creer que un producto se mueve cuando en realidad no es así.

¿Cómo se detectaría?

- Duplicidad: Revisar si existen registros repetidos con el mismo producto, misma fecha y misma cantidad.
- Inconsistencia de fechas: Identificar casos donde la fecha de entrada sea mayor que la fecha de salida.
- Descuadre de cantidades: Comparar el saldo calculado por el sistema con el conteo físico real. Si la diferencia es grande, hay datos erróneos.
- Valores imposibles: Detectar cantidades negativas o cifras muy alejadas del comportamiento habitual.

Justificación

Como señala Redman (2008), la mala calidad de los datos genera decisiones equivocadas con costos muy elevados. Basar decisiones operativas en datos incorrectos es peor que no tener datos. Por eso, antes de analizar, es obligatorio revisar y limpiar la información.

Referencias bibliográficas

- Laney, D. (2017). Las 5 dimensiones del Big Data: Volumen, Velocidad, Variedad, Veracidad y Valor.
- Departamento Nacional de Planeación (2020). Guía de buenas prácticas para el uso y aprovechamiento de datos.
- Redman, T. C. (2008). El impacto económico de la mala calidad de los datos. MIT Sloan Management Review.