

Actividad — Semana 3: Diseño de una arquitectura de datos

Estudiante: Kevin Andres Cuevas Fuentes

Programa: Ingeniería Industrial


Asignatura: Ciencia de Datos

Institución: Corporación Universitaria del Huila — CORHUILA

Periodo: 2026-B

1. Arquitectura del flujo de datos

plaintext



Descripción del flujo

1. Fuentes: Sistema de inventarios y ERP, sistema de facturación y ventas, catálogo de productos, registros de recepción de mercancía y documentos o imágenes de estado de bodega.

2. Ingesta: Se recolectan los datos de forma programada, mediante cargas periódicas por lotes.
3. Almacenamiento: Se integran y guardan en un repositorio estructurado y optimizado para consulta y análisis.
4. Procesamiento: Se limpian, validan y transforman los datos: se calculan indicadores de rotación, se detectan inconsistencias y se agrupan por periodo y producto.
5. Análisis e Inteligencia de Negocio: Se construyen reportes y tableros para visualizar productos de baja rotación, temporadas de acumulación y recomendaciones de gestión.

2. Decisiones de arquitectura

¿Data Warehouse o Data Lake? — Data Warehouse

Se elige Almacén de Datos (Data Warehouse) porque los datos provienen principalmente de sistemas operativos estructurados, con formato conocido y definido. El objetivo es generar reportes y análisis confiables para la toma de decisiones, por lo que se requiere información ya limpia, validada y organizada por temas y tiempos. Un Data Warehouse garantiza consistencia, fiabilidad y facilidad de uso para herramientas de inteligencia de negocio.

Justificación: Según Inmon (2005), considerado el padre del concepto, un almacén de datos es "una colección de datos orientados al tema, integrados, no volátiles y variables en el tiempo, que sirven de apoyo a la toma de decisiones". Al trabajar con datos mayormente estructurados y tener un propósito analítico definido, el Data Warehouse es la opción más adecuada. El Data Lake sería recomendable si se quisiera conservar toda la información en su formato original, especialmente gran volumen de datos no estructurados que aún no se sabe cómo se analizarán; en este caso, no es necesario.

¿Procesamiento Batch o Streaming? — Batch (por lotes)

Se elige procesamiento por lotes porque los datos de inventario y ventas no cambian cada segundo; basta con recolectarlos y procesarlos de forma programada (diaria, semanal o mensual). No se requiere respuesta en tiempo real ni inmediata, ya que las decisiones sobre compras, existencias y promociones se toman de forma periódica.

Justificación: El procesamiento por lotes es la alternativa más conveniente cuando los datos se actualizan en intervalos amplios y no se necesita información al instante.

En cambio, el procesamiento en flujo continuo (streaming) se reserva para casos donde los datos deben procesarse en el mismo momento en que se generan, como transacciones financieras o monitoreo de equipos en tiempo real. En este proyecto, el procesamiento por lotes ofrece mayor simplicidad, menor costo y oportunidad suficiente para la toma de decisiones.

3. Herramientas recomendadas por etapa

Tabla

Etapas	Herramienta candidata	¿Por qué se elige?
Ingesta	Python o consultas SQL	Permiten extraer información de los sistemas empresariales y consolidarla sin necesidad de herramientas complejas. Se adaptan a las fuentes de datos disponibles en la empresa.
Almacenamiento	PostgreSQL o SQL Server	Sistemas de bases de datos relacionales que se ajustan perfectamente al modelo estructurado de inventario, ventas y productos. Garantizan integridad, seguridad y facilidad de consulta.
Procesamiento	Python (Pandas) o SQL	Permiten limpiar registros, detectar errores, calcular indicadores de rotación, agrupar por temporadas y transformar la información antes de visualizarla. Son lenguajes accesibles y muy utilizados en la industria.
Análisis y BI	Power BI	Se integra directamente con bases de datos y archivos procesados. Permite crear tableros visuales, gráficos comparativos y reportes que se pueden compartir con el equipo directivo de forma sencilla.

Referencias bibliográficas

- Inmon, W. H. (2005). *Building the Data Warehouse*. Wiley. Definición y principios del Data Warehouse.

- Marz, N. y Warren, J. (2015). *Big Data: Principles and Best Practices of Scalable Realtime Data Systems*. Manning Publications. Diferencias entre procesamiento por lotes y en tiempo real.
- Chambers, B. y Farley, A. (2020). *Data Architecture: A Primer for the Data Scientist*. Segunda edición. Diferencias y casos de uso entre Data Warehouse y Data Lake.