

ACTIVIDAD PRÁCTICA – SEMANA 9

Ciencia de Datos · Limpieza de un Dataset

Estudiante: Kevin Andrés Cuevas Fuentes

Programa: Ingeniería Industrial

Asignatura: Ciencia de Datos

Periodo: 2026-B

1. Objetivo

Realizar la limpieza de un dataset mediante Python y pandas, identificando y corrigiendo valores faltantes, registros duplicados, tipos de datos incorrectos y formatos inconsistentes en campos de texto. La actividad también documenta el estado antes y después de la limpieza.

2. Dataset utilizado

Se construyó un pequeño dataset de ventas con 8 registros. Para simular problemas reales de calidad se incluyeron un valor nulo en Nombre, un valor nulo en Ventas, un registro duplicado, la edad almacenada como texto y diferencias de mayúsculas, minúsculas y espacios en Ciudad y Nombre.

Dataset antes de la limpieza

ID	Nombre	Edad	Ciudad	Ventas
1	juan perez	25	neiva	1200.0
2	MARIA LOPEZ	30	NEIVA	1500.0
3	Carlos Rojas	28	Bogota	NULO
3	Carlos Rojas	28	Bogota	1800.0
4	ana martinez	35	NEIVA	2100.0
5	PEDRO DIAZ	40	bogota	2500.0
6	NULO	29	Neiva	1700.0
7	lucia torres	31	NEIVA	1900.0

3. Evidencia antes/después

Indicador	Antes	Después
Número de filas	8	7
Valores nulos	2	0
Duplicados	0	0

Interpretación: el dataset pasó de 8 a 7 filas debido a la eliminación del duplicado. Los 2 valores nulos fueron tratados: el nombre faltante se reemplazó por “SIN NOMBRE” y la venta faltante se imputó con la mediana de la columna. Los duplicados quedaron en cero.

4. Código de limpieza en Python (pandas)

```
import pandas as pd
```

```

# Cargar dataset
df = pd.read_csv("dataset_sucio.csv")

# Evidencia antes
print("Filas:", len(df))
print("Nulos:", df.isnull().sum().sum())
print("Duplicados:", df.duplicated().sum())

# Normalizar textos
df["Nombre"] = df["Nombre"].fillna("SIN NOMBRE").astype(str).str.strip().str.title()
df["Ciudad"] = df["Ciudad"].fillna("SIN CIUDAD").astype(str).str.strip().str.title()

# Corregir tipos
df["Edad"] = pd.to_numeric(df["Edad"], errors="coerce")
df["Ventas"] = pd.to_numeric(df["Ventas"], errors="coerce")

# Imputar ventas faltantes con la mediana
df["Ventas"] = df["Ventas"].fillna(df["Ventas"].median())

# Eliminar duplicados
df = df.drop_duplicates().reset_index(drop=True)

# Evidencia después
print("Filas:", len(df))
print("Nulos:", df.isnull().sum().sum())
print("Duplicados:", df.duplicated().sum())

# Guardar dataset limpio
df.to_csv("dataset_limpio.csv", index=False)

```

5. Dataset después de la limpieza

ID	Nombre	Edad	Ciudad	Ventas
1	Juan Perez	25	Neiva	1200.0
2	Maria Lopez	30	Neiva	1500.0
3	Carlos Rojas	28	Bogota	1800.0
4	Ana Martinez	35	Neiva	2100.0
5	Pedro Diaz	40	Bogota	2500.0
6	Sin Nombre	29	Neiva	1700.0
7	Lucia Torres	31	Neiva	1900.0

6. Procesos realizados

Problema	Solución aplicada
Valores nulos en Nombre	Se reemplazó por "SIN NOMBRE".
Valor nulo en Ventas	Se imputó utilizando la mediana de la columna Ventas.
Registro duplicado	Se eliminó mediante <code>drop_duplicates()</code> .
Edad almacenada como texto	Se convirtió a tipo numérico con <code>pd.to_numeric()</code> .
Mayúsculas/minúsculas inconsistentes	Se normalizó el texto con <code>str.title()</code> .
Espacios innecesarios	Se eliminaron con <code>str.strip()</code> .

7. Dimensiones de calidad mejoradas

1. Completitud: esta dimensión mejoró porque se trataron los valores faltantes. El nombre ausente fue reemplazado por una categoría explícita y la venta faltante fue imputada con la mediana. Como resultado, el dataset final no presenta valores nulos.

2. Consistencia: mejoró porque se eliminaron registros duplicados y se unificó la presentación de los campos de texto. Además, Edad y Ventas quedaron representadas como datos numéricos, evitando inconsistencias de tipo que podrían dificultar el análisis posterior.

8. Conclusión

La limpieza permitió transformar un dataset con problemas de nulos, duplicados, tipos de datos y formatos de texto en un conjunto de datos más uniforme y preparado para análisis. El proceso demuestra que pandas permite detectar y corregir problemas de calidad de forma reproducible, además de documentar claramente las diferencias entre el estado inicial y el estado final.

Resultado final: 7 filas, 0 valores nulos y 0 registros duplicados.