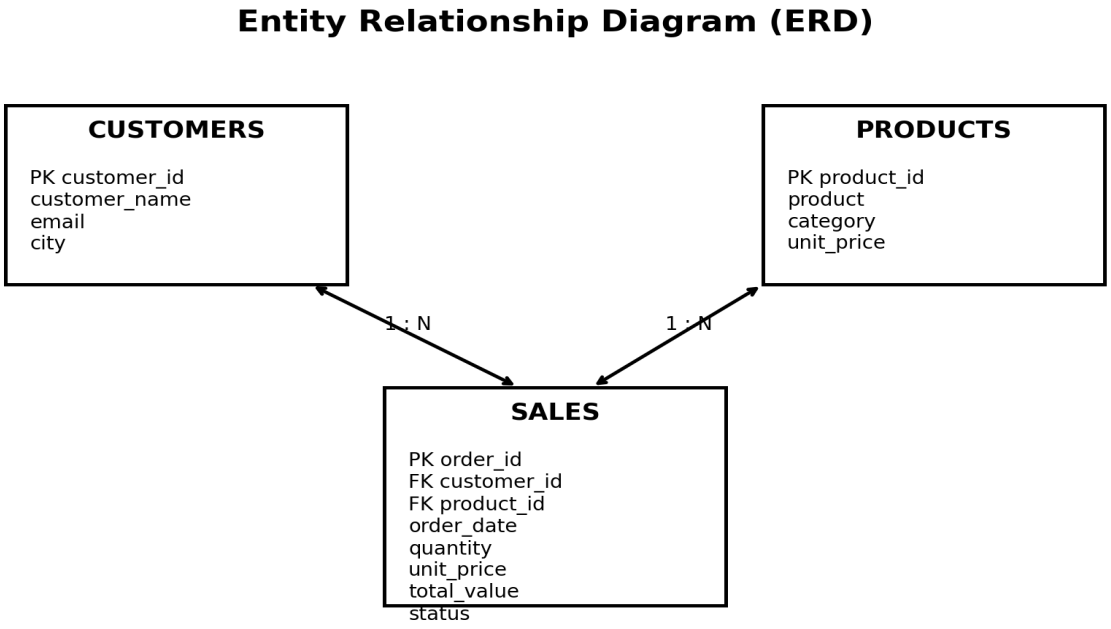
ACTIVIDAD CALIFICABLE – CORTE 2
Modelo, consulta y limpieza de datos

Estudiante: Kevin Andres Cuevas Fuentes
Programa: Ingeniería Industrial
Asignatura: Ciencia de Datos
Semana 4 – Semestre 2026-B

1. Descripción del caso

Se construyó un caso de análisis de ventas. El dataset contiene clientes, productos y transacciones, permitiendo diseñar un modelo con tres entidades relacionadas. El objetivo es limpiar los datos, documentar el antes y después, y responder dos preguntas mediante consultas de agrupación y agregación.

2. Modelo ERD



Cardinalidades: un cliente puede registrar muchas ventas (1:N) y un producto puede aparecer en muchas ventas (1:N).

3. Limpieza de datos – antes y después

Indicador	Antes	Después
Filas	22	21
Columnas	10	11
Valores nulos	2	0
Filas duplicadas	0	0
Fechas	Formatos mixtos	datetime64
Precios	Texto con formatos mixtos	Numérico
Estado	Mayúsculas/minúsculas mixtas	Formato normalizado
Ciudad	Bogota / Bogotá / espacios	Bogotá normalizado

Tratamientos aplicados: limpieza de espacios, normalización de ciudad y estado, conversión de fechas y precios, imputación del email faltante con 'not_provided', imputación de la fecha faltante con la mediana de las fechas válidas, eliminación de la fila

duplicada y creación del valor total de cada venta.

4. Consultas y hallazgos

Pregunta 1: ¿Qué categoría genera el mayor valor de ventas en las órdenes completadas?

Categoría	Ventas completadas
Computers	$9,680,000
Office	$3,450,000
Accessories	$1,745,000
Networking	$1,680,000

Hallazgo: la categoría **Computers** ocupa el primer lugar con $9,680,000. Esto indica que concentra la mayor generación de valor entre las órdenes completadas y puede ser priorizada en inventario y seguimiento comercial.

Pregunta 2: ¿Cuáles son las cinco ciudades con mayor valor de ventas en órdenes completadas?

Ciudad	Ventas completadas
Neiva	$6,475,000
Bogotá	$4,860,000
Aipe	$1,200,000
Palermo	$1,120,000
Pitalito	$820,000

Hallazgo: Neiva presenta el mayor valor de ventas completadas con $6,475,000. La concentración geográfica puede servir para orientar inventario, campañas y capacidad de atención.

5. Conclusión

El proceso permitió transformar un dataset con inconsistencias en una base lista para análisis. La normalización de formatos, tratamiento de valores faltantes, eliminación de duplicados y creación de una variable calculada mejoran la calidad y trazabilidad de la información. El modelo de tres entidades facilita representar clientes, productos y ventas, mientras que las consultas permiten obtener hallazgos útiles para la toma de decisiones.

6. English requirement – Data & cleaning

- This project uses a sales dataset with customers, products and transactions.
- The cleaning process standardized text, dates, numeric prices and order status.
- Missing values were handled and the duplicated row was removed.
- A total_value field was created by multiplying unit price by quantity.
- The first query identifies the category with the highest completed sales.
- The second query identifies the five cities with the highest completed sales.
- The results can support inventory planning and commercial decisions.