INFORME DE ACTIVIDAD PRÁCTICA

SEMANA 10 — MINI-PROYECTO DE DATOS (CIERRE C2)

Estudiante: Kevin Andrés Cuevas Fuentes

Programa: Ingeniería Industrial

Asignatura: Ciencia de Datos · **Periodo:** 2026-B

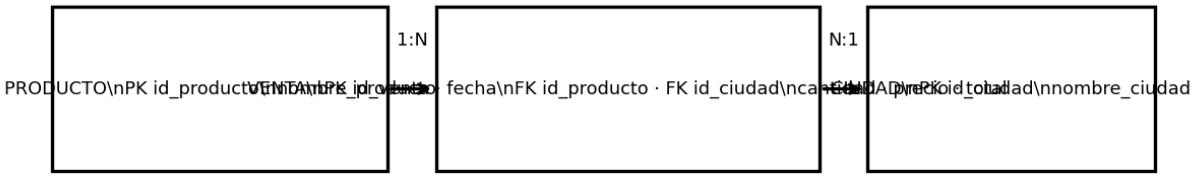
Caso de estudio: ventas simuladas de una tostadora de café del Huila.

1. Introducción

La actividad integra un modelo de datos, carga y limpieza de un dataset, dos consultas de análisis y documentación del flujo extraer → limpiar → analizar. El caso se desarrolla con datos simulados de ventas de café.

2. Modelo de datos (ERD)

El modelo conceptual tiene tres entidades: Producto, Ciudad y Venta. Un producto puede aparecer en muchas ventas y una ciudad puede registrar muchas ventas. Cada venta se asocia con un producto y una ciudad.



Entidad	Atributos principales	Uso
Venta	id_venta (PK), fecha, cantidad, precio_unitario, total_venta, id_producto (FK), id_ciudad (FK)	Registra cada transacción
Producto	id_producto (PK), nombre_producto	Clasifica el artículo
Ciudad	id_ciudad (PK), nombre_ciudad	Identifica el mercado

Para simplificar el archivo CSV, se conservan producto y ciudad como nombres descriptivos; el diagrama representa cómo se organizarían en un modelo relacional normalizado.

3. Extracción y limpieza

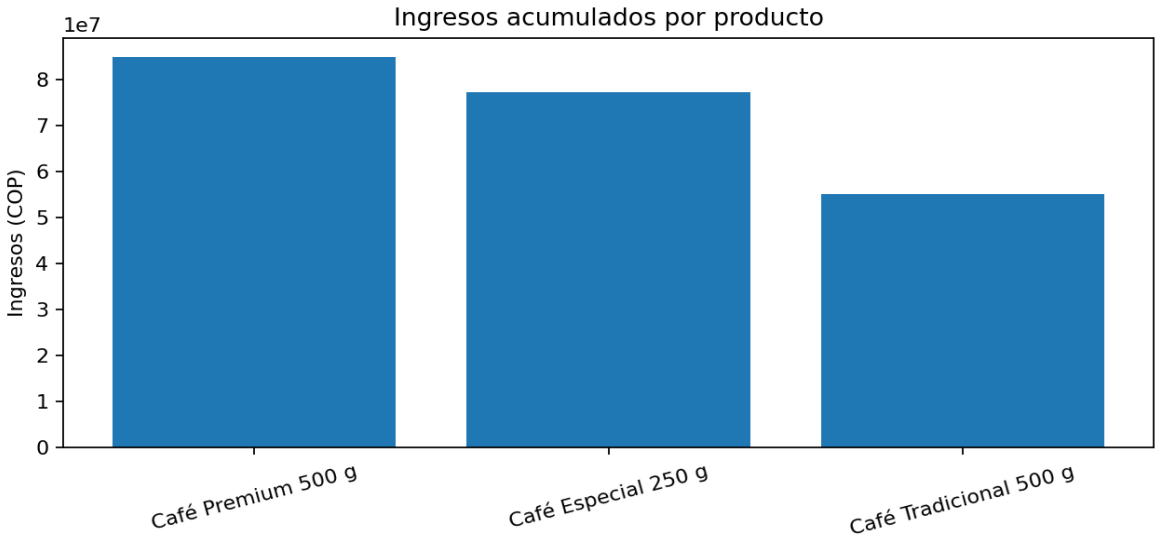
El script carga el CSV con pandas, convierte la fecha a datetime y los campos numéricos a valores numéricos, normaliza espacios y uso de mayúsculas, elimina filas con campos esenciales vacíos, descarta cantidades o precios no positivos y elimina duplicados por id_venta. Después recalcula total_venta = cantidad × precio_unitario.

El archivo original tiene 252 registros; tras la limpieza quedan 250 registros válidos. Los datos se simularon para esta práctica y no representan operaciones reales.

4. Análisis 1: ¿qué producto genera mayores ingresos?

Se agrupan los registros por producto y se suman los ingresos totales. El resultado se ordena de mayor a menor.

Producto	Ingresos acumulados (COP)
Café Premium 500 g	$84,786,000
Café Especial 250 g	$77,117,000
Café Tradicional 500 g	$55,023,500



Interpretación: el producto ubicado en la primera fila es el que más ingresos acumula en el periodo. Esta comparación puede apoyar decisiones de inventario y promoción.

5. Análisis 2: ¿qué ciudad registra mayores ventas durante 2026?

Se filtran las fechas correspondientes a 2026 y se agrupan los ingresos por ciudad.

Ciudad	Ingresos 2026 (COP)
Neiva	$26,271,000
La Plata	$26,257,500
Garzón	$25,911,500
Pitalito	$24,484,500

Interpretación: la ciudad que aparece primero presenta el mayor ingreso acumulado en los registros de 2026. La comparación permite evaluar mercados con el mismo criterio.

6. Documentación del flujo

Extraer: leer el CSV. **Limpiar:** tratar tipos, textos, faltantes y valores no válidos. **Analizar:** agregar por producto y por ciudad con filtro del año 2026. **Exportar:** guardar datos limpios, tablas y gráfico en la carpeta salidas.

7. Conclusiones

El proceso reproducible en pandas transforma registros transaccionales en información útil. La limpieza evita distorsiones y las dos agregaciones responden preguntas concretas. Como la información es simulada, los resultados solo ilustran el método analítico.

Anexos: semana10.py, ventas_tostadora_huila.csv, ventas_limpias_referencia.csv y modelo_ERD.png.